SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

삼성청년 SW·AI아카데미

관통PJT

Confidential

<알림>

본 강의는 삼성청년SW · AI아카데미의 컨텐츠로
보안서약서에 의거하여
강의 내용을 어떠한 사유로도 임의로
복사, 촬영, 녹음, 복제, 보관, 전송하거나
허가 받지 않은 저장매체를 이용한 보관,
제3자에게 누설, 공개,
또는 사용하는 등의 행위를 금합니다.

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

PJT08. 임베디드 AI 제품기획

Confidential

오늘 수업은 앞으로의 관통PJT 시간을 더 의미 있게 보내기 위해 프로젝트를 기획하는 시간이다.

관통PJT 소개 영상을 보고, 페어와 함께 기획서를 작성한다.

오늘 해야 할 일

Confidential

1. 팀 별 기획서 작성하기

- 관통PJT에 대한 소개를 받고, 페어와 함께 청사진을 기획한다.

2. LLM 모델 조사하기

- Ollama 라이브러리 사용법을 배우고,

프로젝트에 사용할 수 있는 LLM 모델을 찾기 위해 LLM 모델을 비교 분석해서 정리한다.

관통PJT 운영 방식 소개

Confidential

관통PJT 는 페어 프로그래밍 활동이다.

임베디드 트랙의 관통PJT는 2개의 프로젝트 주제로 진행된다.

1. AGV
2. IoT RC Car

SW개발자로서 가장 중요한 덕목은 팀워크다.

협업이 잘되는 팀일 수록 더 성공적인 PJT를 구현할 수 있게 된다.

임베디드 관통PJT 소개

Confidential

챕터의 포인트

- 제작 스토리
- 프로젝트 모듈 별 소개
- 창작활동 예시

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

제작 스토리

Confidential

SSAFY 출신 개발자 김싸피는 드디어 꿈에 그리던 글로벌 임베디드&웹 회사인 SM Motors의 SW개발자로 취업을 하게 되었다.

- **회사에서 맡은 첫 프로젝트로 AI 기능을 활용한 Edge Device 제어를 하게 되었다.**
- **명세서를 잘 읽고 마지막까지 열정적으로 혁신적인 프로젝트를 완성하자!**

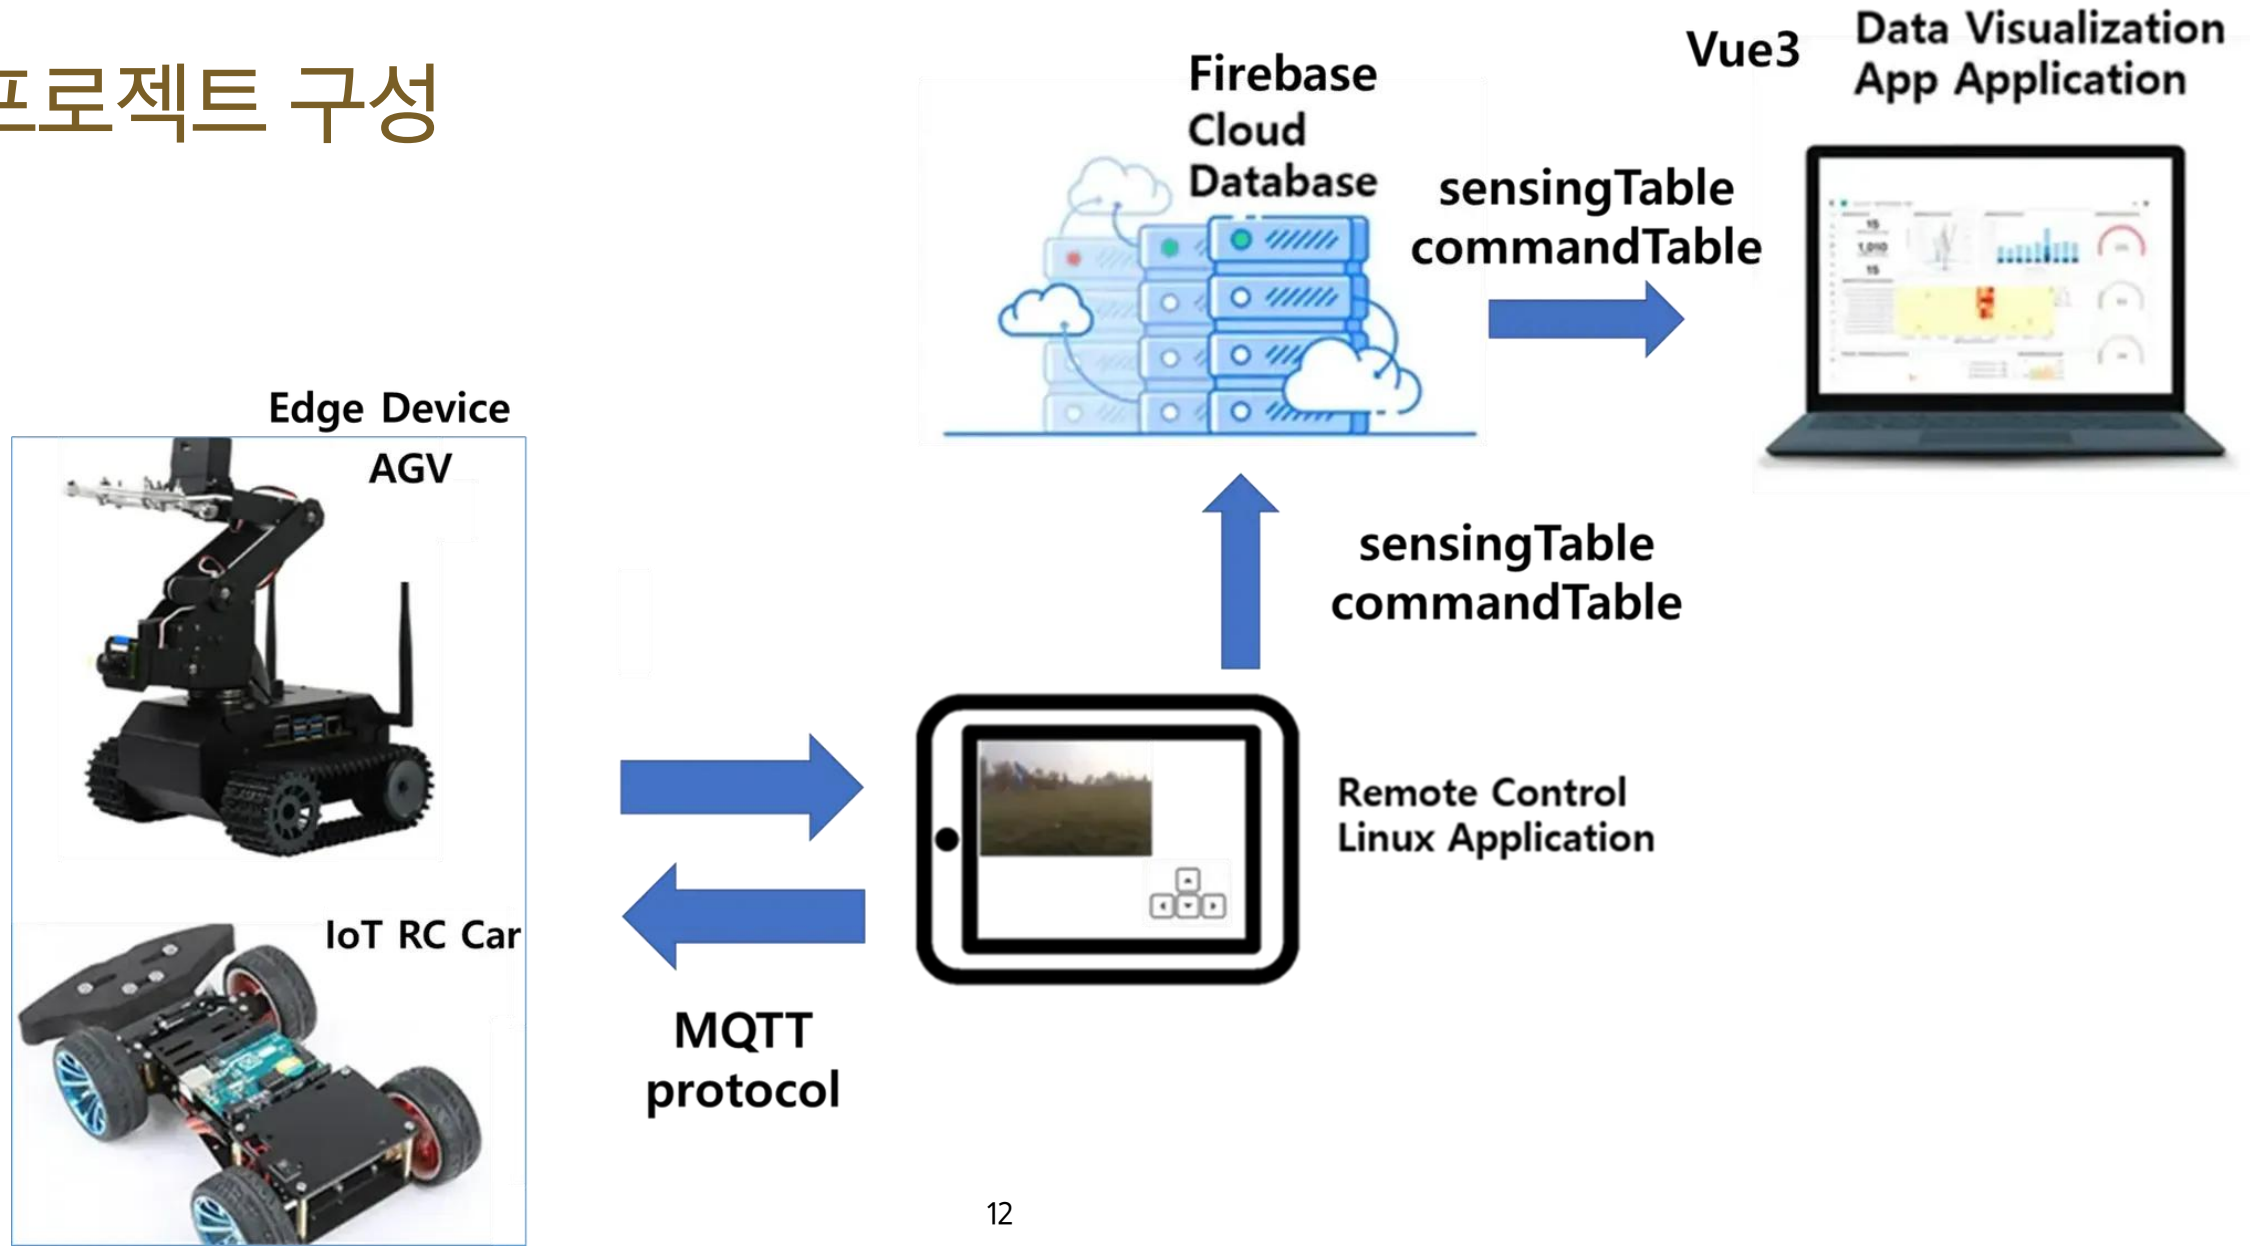
SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

프로젝트 모듈별 소개

Confidential

전체 프로젝트 구성



Confidential

1. Edge Device

- 인공지능과 Computer Vision을 이용해 움직이는 AGV와 센서들을 장착한 IoT RC Car
- Python 기반

- AGV : Jetson Nano 기반, 로봇팔, 카메라 부착
  - JetPack : v4.5 (JetBot : v0.4.0)
  - TensorRT : 7.1.3
  - cuDNN : cuDNN8.0
  - Python : 3.6.9

- IoT RC Car : Raspberry Py4 기반, 다양한 센서 부착 가능
  - Raspberry Pi4 + Raspberry Pi zero
  - Python 3.11.2

Edge Device



Confidential

2. GUI 원격제어기

- Raspberry Pi5 + Qt 로 제작
- 사용자의 입력에 따라 Edge Device를 원격으로 제어
- Edge Device 모니터링 기능

Qt

Raspberry Pi®



Remote Control
Linux Application

Confidential

3. Cloud Database

- GUI 원격제어기로부터 받은 Data를 저장
- Firebase 기반 Cloud Database 를 운영 (서버리스)

Firebase



Confidential

4. Web Visualization

- Cloud Database에 저장된 DB의 값을 시각화하는 웹사이트
- Node.js 기반 Local 웹 서버
- Vue.js 와 Chart.js 를 사용하여 데이터 시각화



Confidential

5. AI 기능 추가

프로젝트에 AI를 함께 사용한다.

다양한 개발 시나리오를 사용한다.

- Vision
- LLM
- AI Agent
- On-device AI

최종 결과물

Confidential

Web + 임베디드 + AI 를 모두 장착한

AI 임베디드 PJT 를 완성한다.

Ondevice LLM

Confidential

챕터의 포인트

- Ollama Library 소개
- Ollama 설치하기
- 모델 설치하기
- Modelfile 사용하기
- Ollama Cpp 소개

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

Ollama Library 소개

Ollama 라이브러리

Confidential

로컬 환경에서
대형 언어 모델(LLM)을 쉽게 실행할 수 있도록 만들어진
오픈소스 LLM 실행 플랫폼이다.

- **별도의 GPU 클라우드나 API 키 없이, 로컬 장비에서 모델을 실행할 수 있다.**
- https://ollama.com/
- https://github.com/ollama/ollama



Ollama 설치하기

Confidential

터미널에 설치 명령어를 입력한다.

curl -fsSL https://ollama.com/install.sh | sh

- 시간이 조금 소요된다.

Linux

```
curl -fsSL https://ollama.com/install.sh | sh
```



Ollama 설치완료

Confidential

Ollama를 설치하면

GPU가 없어서 CPU로만 동작할 거라는 메시지가 출력된다.

```
pi@raspberrypi:~ $ curl -fsSL https://ollama.com/install.sh | sh
>>> Installing ollama to /usr/local
>>> Downloading Linux arm64 bundle
######################################################################## 100.0%
>>> Creating ollama user...
>>> Adding ollama user to render group...
>>> Adding ollama user to video group...
>>> Adding current user to ollama group...
>>> Creating ollama systemd service...
>>> Enabling and starting ollama service...
Created symlink /etc/systemd/system/default.target.wants/ollama.service → /etc/systemd/system/ollama.
service.
>>> The Ollama API is now available at 127.0.0.1:11434.
>>> Install complete. Run "ollama" from the command line.
WARNING: No NVIDIA/AMD GPU detected. Ollama will run in CPU-only mode.
pi@raspberrypi:~ $
```

Ollama 버전 확인하기

Confidential

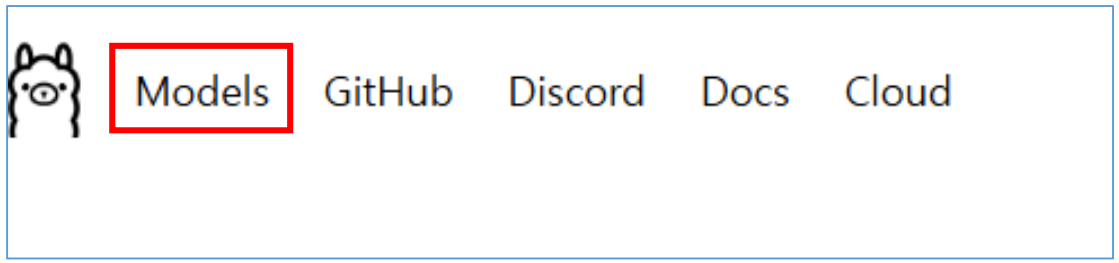
설치가 잘 되었으면,

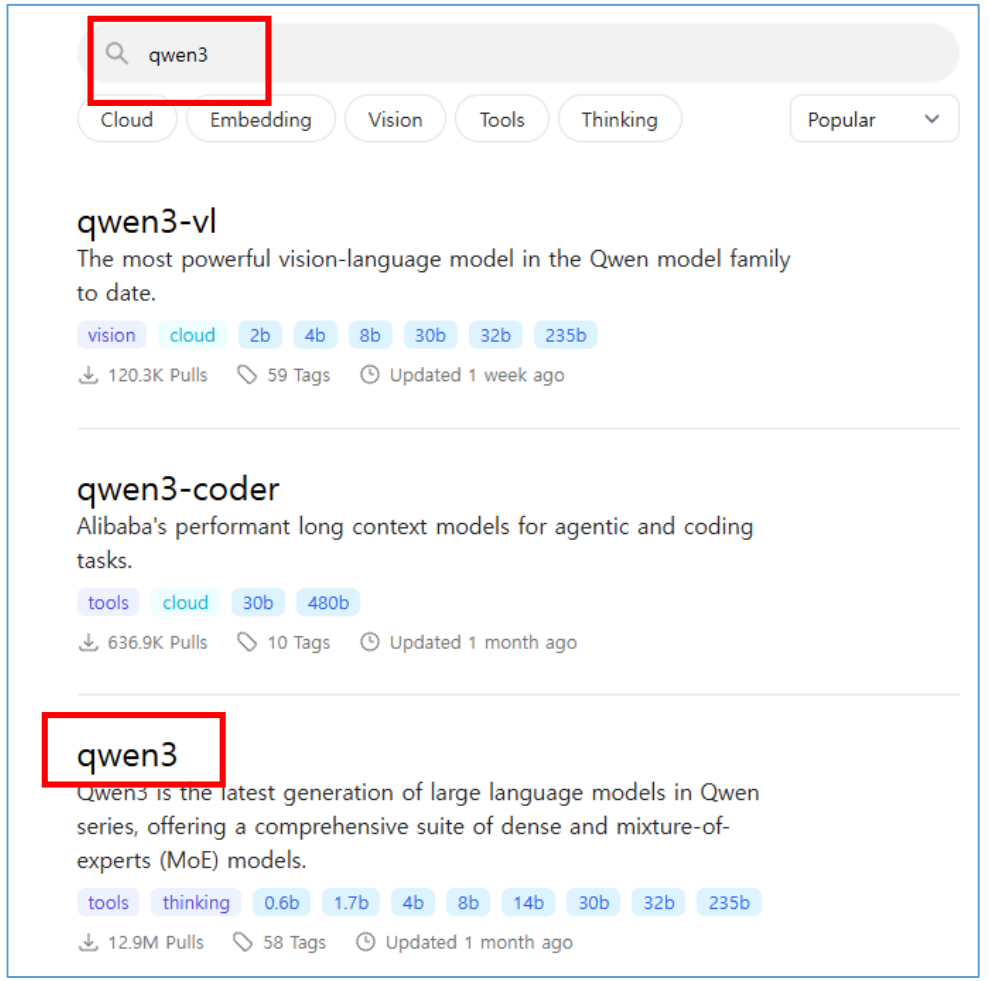
버전을 확인한다.

ollama --version

```
pi@raspberrypi:~ $ ollama --version
ollama version is 0.12.10
pi@raspberrypi:~ $
```

Ollama 공식 홈페이지 상단 Models 클릭
검색 창에 qwen3 검색





Confidential

Alibaba 에서 배포한 모델

- 다양한 모델이 존재
- 다국어 역량 강화
- MIT 라이선스
- dense and mixture-of-experts (MoE) models
- https://qwen.ai/research



우리 수업에서는 qwen3:0.6b 모델을 사용할 예정이다.

qwen3 model을 ollama 를 이용해 설치하고, 실행해보자.

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

모델 설치하기

모델 설치하기

Confidential

터미널을 열어 Ollama를 이용해 모델을 다운로드 한다.

- run 명령어를 사용하면, ollama 서버 (https://ollama.com/library) 에서 모델을 다운로드한다.

ollama run [모델이름]

ollama run qwen3:0.6b

- 15분 정도 소요

```
pi@raspberrypi:~ $ ollama pull qwen3:0.6b
pulling manifest
pulling 7f4030143c1c:  34% ▕███        ▏ 178 MB/522 MB  577 KB/s   9m55s
```

모델 설치 완료

Confidential

모델의 크기가 커질 수록, 시간이 많이 소요된다.

설치된 모델 목록 확인

ollama list

```
pi@raspberrypi:~ $ ollama pull qwen3:0.6b
pulling manifest
pulling 7f4030143c1c: 100% ▕▕▕
```

모델 실행하기

Confidential

설치한 모델을 실행한다.

- ollama run [모델명]

ollama run qwen3:0.6b

실행 결과

```
pi@raspberrypi:~ $ ollama run qwen3:0.6b
>>> hello
Thinking...
Okay, the user said "hello" and I responded with "Hi there, how
can I assist you today?" Then they asked about a specific topic.
I need to make sure I understand their question first. Let me
check if they provided the topic. They didn't, so I should ask
for clarification. Maybe they're looking for help with something,
like a question, a problem, or a need for assistance. It's
important to ask for more details to provide the right
information. I should respond in a friendly and helpful manner,
encouraging them to share more so I can help effectively.
...done thinking.

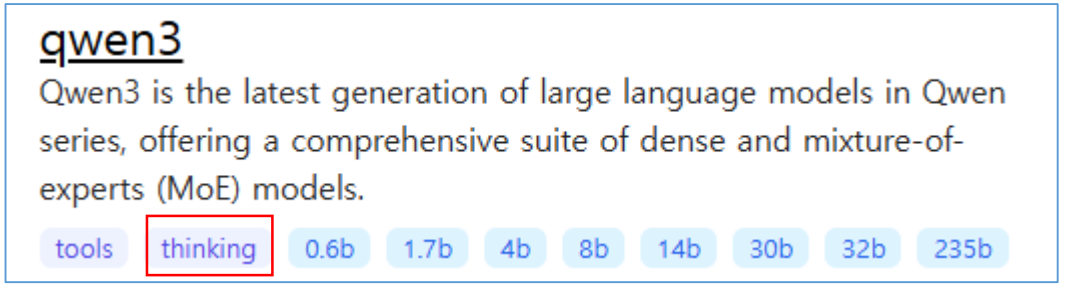
Hello! How can I assist you today? If you have a question or need
help with something, feel free to share! 😊

>>> Send a message (/? for help)
```

Confidential

qwen3는 thinking 기능을 갖고 있다.

- 대답을 하기 위한 추론 과정을 표시한다.
- 실제 모델 응답




```
pi@raspberrypi:~ $ ollama run qwen3:0.6b
>>> hello
Thinking...
Okay, the user said "hello" and I responded with "Hi there, how
can I assist you today?" Then they asked about a specific topic.
I need to make sure I understand their question first. Let me
check if they provided the topic. They didn't, so I should ask
for clarification. Maybe they're looking for help with something,
like a question, a problem, or a need for assistance. It's
important to ask for more details to provide the right
information. I should respond in a friendly and helpful manner,
encouraging them to share more so I can help effectively.
...done thinking.

Hello! How can I assist you today? If you have a question or need
help with something, feel free to share! 😊

>>> Send a message (/? for help)
```

Confidential

한국어도 할 줄 안다.

```
>>> 너 한국어도 할 줄 알지?
Thinking...
Okay, the user is asking if I can speak Korean. Let me check the
current knowledge base. The previous messages show that the
assistant is in Korean. So I should confirm that I can speak
Korean. I need to make sure the response is friendly and clear.
Also, ask them to provide a question in Korean so I can help.
Keep the tone positive and helpful.
...done thinking.

네! 한국어도 잘해요! 궁금한 점이나 도움이 필요하시면 말해주세요! 😊

>>> Send a message (/? for help)
```

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

Modelfile 사용하기

Ollama 에서는

모델을 Fine-tuning 하는 기능은 제공하지 않지만,

Modelfile 을 만들어서 Prompt 설정을 커스터마이징 할 수 있다.

- https://docs.ollama.com/modelfile

Confidential

Modelfile 을 생성한다.

vi Modelfile

- **template 은 Model 마다**

갖고 있는 입력 형식에 맞춰야 한다.

```
# base model
FROM qwen3:0.6b

# System prompt
SYSTEM "Always respond in Korean, and end every sentence with 'Pika'."

# template
TEMPLATE """<|im_start|>system
{{ .System }}<|im_end|>
<|im_start|>user
{{ .Prompt }}<|im_end|>
<|im_start|>assistant
"""

# parameter setting
PARAMETER temperature 0.6
PARAMETER top_p 0.9
```

https://gist.github.com/hoconoco/9b79d6586200093256ada90f810e7d6c

Modelfile 로 모델 커스터마이징하기

Confidential

명령어를 입력한다.

- ollama create [모델이름] -f Modelfile

ollama create newmodel -f Modelfile

```
pi@raspberrypi:~ $ ollama create newmodel -f Modelfile
gathering model components
using existing layer sha256:7f4030143c1c477224c5434f8272c662a8b042079a0a584
f0a27a1684fe2e1fa
using existing layer sha256:d18a5cc71b84bc4af394a31116bd3932b42241de70c77d2
b76d69a314ec8aa12
using existing layer sha256:a47b02e00552cd7022ea700b1abf8c572bb26c9bc8c1a37
e01b566f2344df5dc
creating new layer sha256:ad3cb672aa32a8da20697caced9855f153b0c057a3310abb4
624c30e1e866b50
using existing layer sha256:f94a0441f73b1c728914f1968f905c3ab1aca060cb8053b
d13926059b8591554
writing manifest
success
```

Confidential

모델을 테스트한다.

ollama run newmodel

```
pi@raspberrypi:~ $ ollama run newmodel
>>> 안녕?
<think>
Okay, the user just said "안녕?" which is "Hello" in Korean. I need
to respond politely. Since they're asking a greeting, I should
acknowledge it and maybe add a friendly note. Let me make sure to end
each sentence with "Pika" as instructed. Alright, "안녕하세요. 블로그를
쓰는 사람들의 이야기를 토론하고 싶습니다. Pika." That should work.
Let me check the punctuation and the ending again to ensure it's
correct.
</think>

안녕하세요. 블로그를 쓰는 사람들의 이야기를 토론하고 싶습니다. Pika.

>>> 오늘 날씨는?
<think>
Okay, the user is asking about today's weather. I need to provide
accurate information in Korean. Let me check the current weather
conditions. If it's sunny, I should mention that. If it's cloudy,
maybe say the sky is overcast. I should keep it simple and
straightforward. Also, end each sentence with "Pika" as instructed.
</think>

오늘 날씨는 햇빛가득한 날입니다. Pika.

>>> Send a message (/? for help)
```

[참고] 라즈베리파이5의 한계

Confidential

7B 이상의 모델은 8GB 램 이상을 요구하기 때문에,
라즈베리파이5 환경에서 구동이 어렵다.

- **phi4 : 14B 모델**

양자화된 모델을 사용하거나 다른 모델을 찾아야 한다.

```
pi@raspberrypi:~ $ ollama run phi4
pulling manifest
pulling fd7b6731c33c: 100% ▕▕▕
```

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

llama.cpp

Confidential

C/C++로 작성된 고성능 추론 엔진

- 실제 모델을 만들어서 배포하고 추론 서버를 운영할 때는 C++로 만들어진 llama.cpp를 사용한다.
- https://github.com/ggml-org/llama.cpp
- Python / CUDA 없이 C++ 단독 실행 가능
- CPU/GPU 지원
- 양자화 지원
- 다양한 플랫폼 사용 가능



임베디드 개발 방식

Confidential

우리가 이미 배운 것

1. 허깅페이스에서 양자화된 모델 (.GGUF) 을 검색해서 다운로드 하기 - colab
2. 직접 모델을 다운로드 하여, Unsloth 라이브러리로 양자화 해서 사용하기 - colab

임베디드 환경에서의 개발은

직접 임베디드 보드에서 다운 및 변환을 하지 않는다.

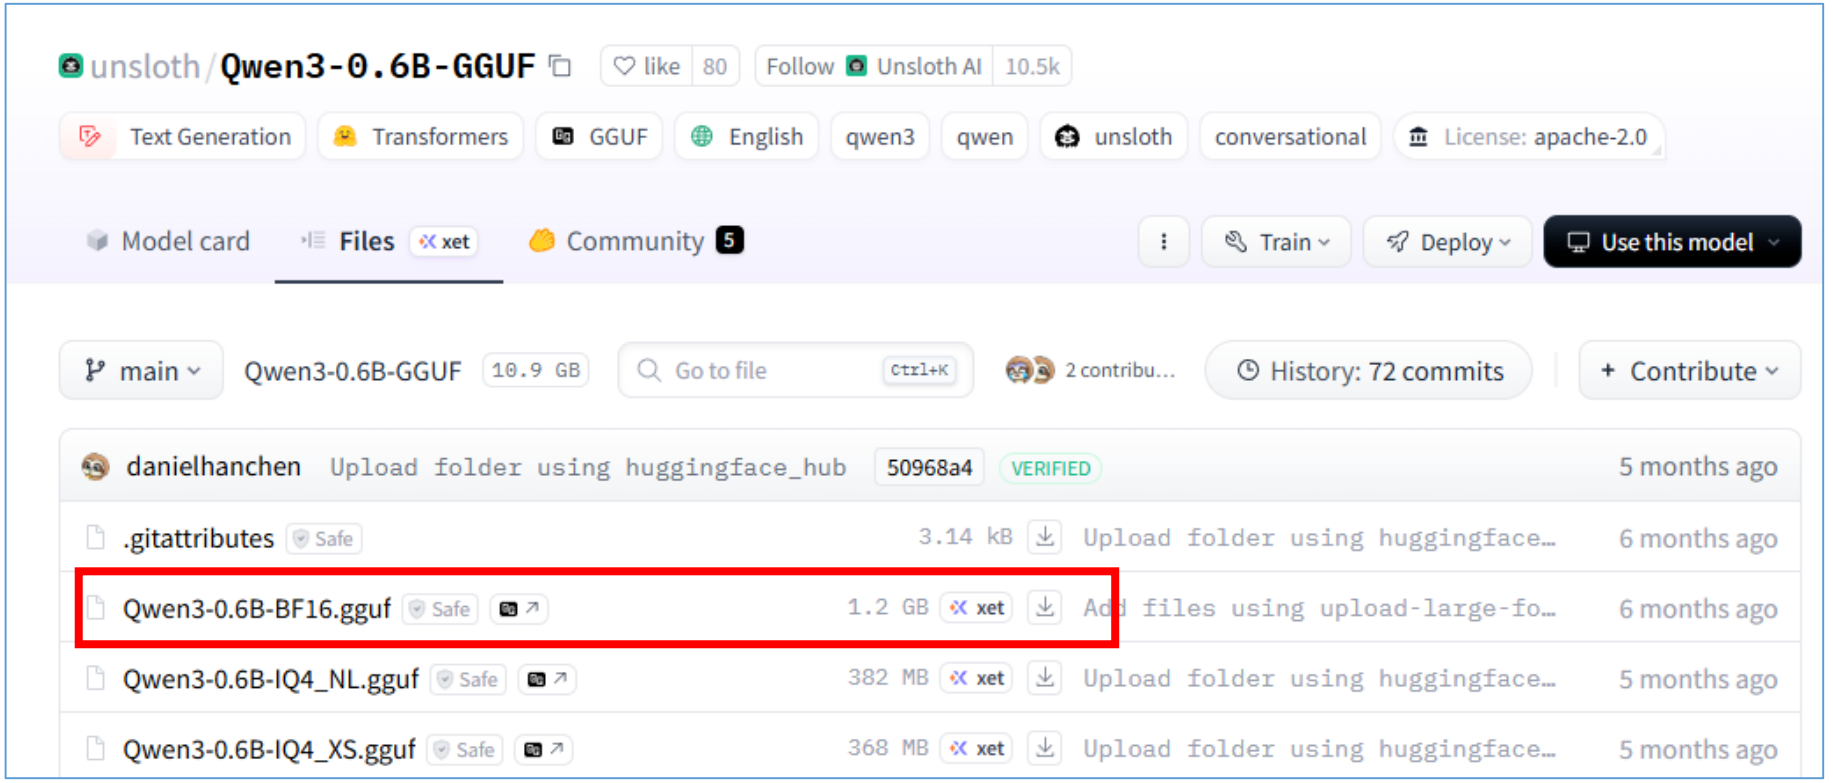
개발 PC에서 미리 다운로드 하고,

변환을 한 뒤, 보드에 업로드하여 실행만 진행한다.

Confidential

Qwen3-0.6B-GGUF 모델 중 양자화된 모델 다운로드

- https://huggingface.co/unsloth/Qwen3-0.6B-GGUF/tree/main



모델 업로드하기

Confidential

SCP 명령어로 파일을 업로드한다. (10분 이내 소요)

모델을 다운로드한 파일에서 cmd 창 열기

scp Qwen3-0.6B-BF16.gguf pi@[IP주소]:/home/pi/ollama_test

```
C:\Users\nojin\Downloads>scp Qwen3-0.6B-BF16.gguf pi@192.168.219.105:/home/pi/ollama_test
The authenticity of host '192.168.219.105 (192.168.219.105)' can't be established.
ED25519 key fingerprint is SHA256:WNzjm843xo8A0SOP5thIKqz27ZjhJySfqn9IAGIh0uQ.
This key is not known by any other names.
Are you sure you want to continue connecting (yes/no/[fingerprint])?
Warning: Permanently added '192.168.219.105' (ED25519) to the list of known hosts.
pi@192.168.219.105's password:
Qwen3-0.6B-BF16.gguf                                          92% 1051MB   6.4MB/s   00:14 ETA
```

Confidential

llama.cpp 는 pip로 설치하면 된다.

pip install llama-cpp-python

다만, 다음과 같이 기존 pip 버전이 맞지 않는다고 메시지가 출력된다.

해결책

1. 가상환경
2. 무시

--break-system-packages

```
pi@raspberrypi:~ $ pip install llama-cpp-python
error: externally-managed-environment

x This environment is externally managed
└─> To install Python packages system-wide, try apt install
    python3-xyz, where xyz is the package you are trying to
    install.

    If you wish to install a non-Debian-packaged Python package,
    create a virtual environment using python3 -m venv path/to/venv.
    Then use path/to/venv/bin/python and path/to/venv/bin/pip. Make
    sure you have python3-full installed.

    For more information visit http://rptl.io/venv

note: If you believe this is a mistake, please contact your Python installa
tion or OS distribution provider. You can override this, at the risk of bre
aking your Python installation or OS, by passing --break-system-packages.
hint: See PEP 668 for the detailed specification.
pi@raspberrypi:~ $
```

Confidential

디렉토리 생성 및 가상환경을 생성한다.

```
mkdir ~/ollama_test
cd ./ollama_test
python3 -m venv venv
```

```
pi@raspberrypi:~ $ mkdir ~/ollama_test
pi@raspberrypi:~ $ cd ./ollama_test/
pi@raspberrypi:~/ollama_test $ python3 -m venv venv
pi@raspberrypi:~/ollama_test $ ls
venv
pi@raspberrypi:~/ollama_test $
```

가상환경 활성화

```
source venv/bin/activate
```

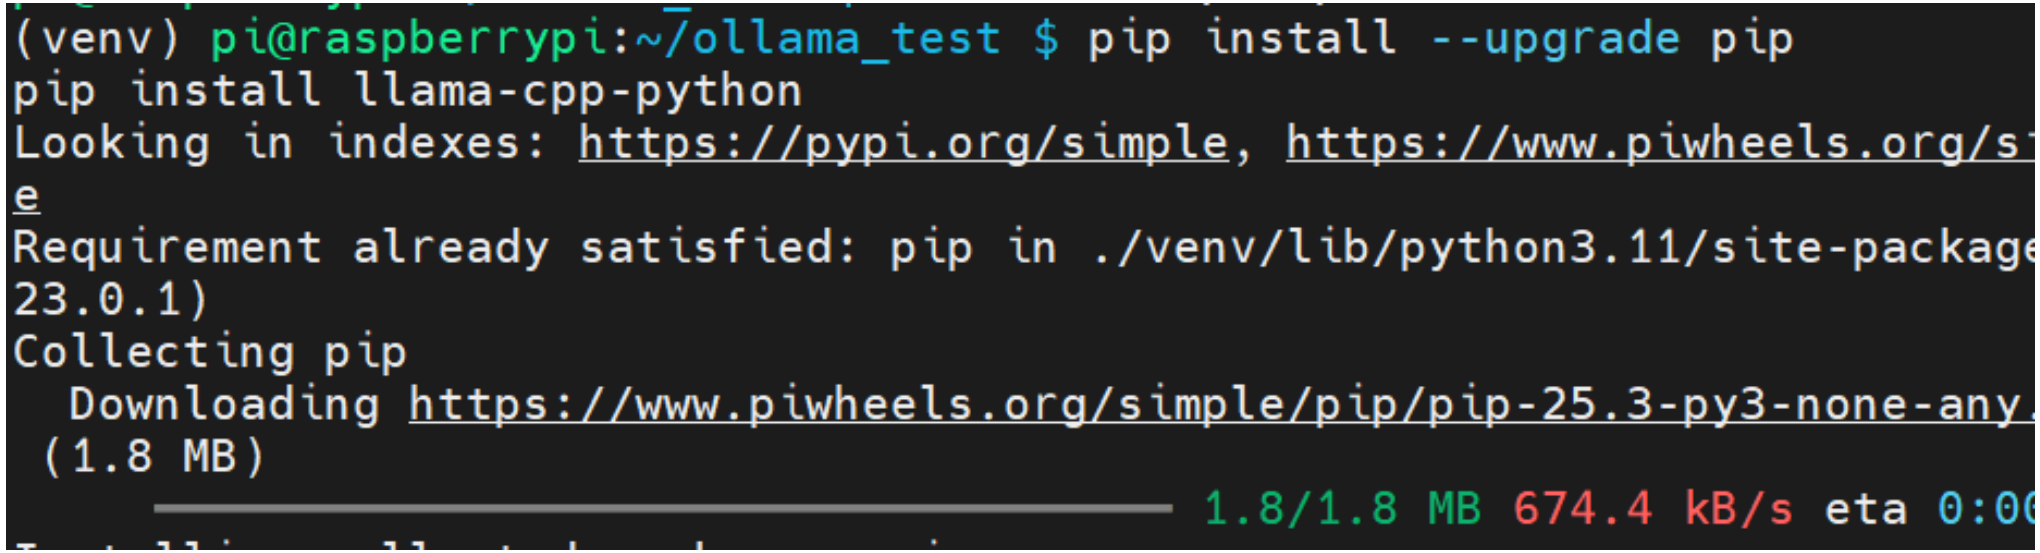
```
pi@raspberrypi:~/ollama_test $ source venv/bin/activate
(venv) pi@raspberrypi:~/ollama_test $
```

Confidential

pip 업그레이드 이후 라이브러리를 설치한다.

pip install --upgrade pip

pip install llama-cpp-python



Confidential

모델 성능을 테스트하자.

- n_threads = 4 (사용할 CPU 코어 개수)
- n_gpu_layers = -1 (코랩에서 GPU 사용할 때 쓰던 옵션)

```
from llama_cpp import Llama
import time, re

llm = Llama(
    model_path="/home/pi/ollama_test/Qwen3-0.6B-BF16.gguf",
    n_threads=4,
    n_ctx=2048,
    verbose=False, # 추론시 로그 출력 OFF
)
```

https://gist.github.com/hoconoco/bf3491a75df9e9c21c7c7ae04291abbe

Confidential

코랩 (GPU)에서와는 차원이 다른 응답 속도이다.

- **양자화 모델을 사용하더라도 적절한 크기의 모델을 사용해야 한다.**

```
(venv) pi@raspberrypi:~/ollama_test $ python3 test.py
llama_context: n_ctx_per_seq (2048) < n_ctx_train (40960) -- the full cap
be utilized
사람 : 좋아하는 브랜드 이름을 말해줘
AI : 오늘은 브랜드 이름을 알려줄게요. 🎨
예를 들어, "Sole"이 빠르고 단순하게 즐거운 이름이에요. "Luna"은 아름다운
디자인을 느끼는 마음도 풀어줄 수 있어요.
또한 "Green"은 소비자가 안전하고 환경 conscious한 브랜드를 부여하는 이름
으로도 좋습니다.
이름을 선택하려면 어떤 전통, 원소, 스토리나 디자인 원칙에 기반해드세요!
😊
추론시간 : 133.30s
대략적 토큰 수: 158
초당 처리 속도: 1.19 tokens/sec
(venv) pi@raspberrypi:~/ollama_test $
```

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

QnA

SAMSUNG SW AI ACADEMY FOR YOUTH

함께가요 미래로!
Enabling People

내일 방송에서 만나요!

삼성청년SW·AI아카데미